ESCUELA POLITÉCNICA NACIONAL
Facultad de Ingeniería de Sistemas · Carrera de Ciencia de Datos e Inteligencia Artificial

INFORME DE LABORATORIO · SEMANA 3

Clasificación de variables Y población vs. Muestra

Laboratorio complementario · Semana 3
Asignatura IDSD422 — Estadística y Programación para Ciencia de Datos I

Estudiante(s)	Quilumba Diaz Guido Fidel · usuario de GitHub: fidel2006q
Docente	Christian Suárez
Período académico	2026-B
Fecha de entrega	23/10/2026
Repositorio (fork)	https://github.com/fidelq2006/IDSD422-lab-muestreo-poblacion.git

Estructura del informe, sección por sección

1 · Introducción

Como estudiante y responsable de este análisis, el presente informe detalla el desarrollo y los resultados obtenidos a partir de la base de datos de fidelización de la empresa *RetailAndina S.A.*. El propósito fundamental de este trabajo es: estructurar y clasificar rigurosamente las variables estadísticas del conjunto de datos inicial mediante criterios lógicos y técnicos, además, evaluar empíricamente el comportamiento de diferentes metodologías de muestreo frente a parámetros poblacionales conocidos. Comparo el rendimiento del muestreo aleatorio simple y el estratificado sobre una población total de 400 clientes, analizando la variabilidad inherente a las distintas semillas y su impacto directo en la solidez de cualquier conclusión gerencial. Este ejercicio consolida una perspectiva crítica indispensable para la correcta interpretación de datos en la práctica profesional.

2 · Objetivos

Objetivo general

Analizar rigurosamente la base de datos de fidelización de RetailAndina S.A. mediante la clasificación formal de variables y la evaluación comparativa de métodos de muestreo, con el fin de proporcionar a la gerencia una base analítica sólida para la toma de decisiones basada en datos.

Objetivos específicos

1. Clasificar formalmente las variables del conjunto de datos aplicando criterios lógicos y técnicos, reconociendo la naturaleza estadística de cada una más allá de su almacenamiento predeterminado.

2. Evaluar el rendimiento empírico de tres diseños de muestreo (conveniencia, aleatorio simple y estratificado) sobre la población total de clientes, identificando la presencia de sesgos de selección y el impacto de la variabilidad entre distintas semillas.

3. Evidenciar la práctica mediante capturas de pantalla, para realizar el respectivo informe.

3 · Desarrollo de la práctica

3.1. Completar el archivo muestreo.py

Desarrollé el script en GOOGLE COLAB para analizar una población de 400 clientes, aplicando tres métodos de muestreo (conveniencia, aleatorio simple y estratificado) con el fin de estimar el ingreso mensual promedio. Esto sirvió para comparar los resultados frente al parámetro real y evaluar sesgos de selección y variabilidad.

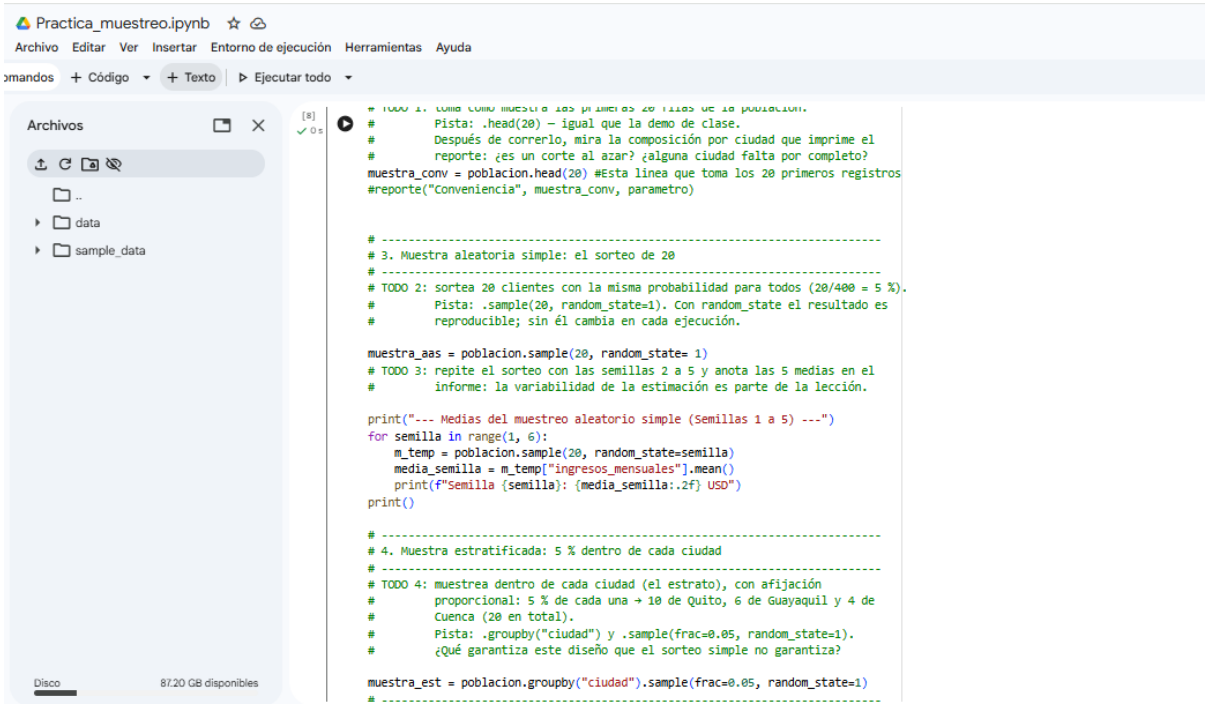


Figura 1. TODOS del archivo muestreo.py

3.2. Completar el archivo muestreo.R

Lo mismo que el anterior archivo, pero ahora un script en R. Con el fin de analizar una población de 400 clientes, aplicando muestreos por conveniencia, aleatorio simple y estratificado. Esto permitió estimar el ingreso mensual promedio, evaluar sesgos de selección y comparar los resultados con el parámetro real.

De igual forma, lo desarrollé en GOOGLE COLAB ejecutando el comando el siguiente comando: "%load_ext rpy2.ipython ", y poder trabajar ahí mismo sin la necesidad de hacerlo en POSIT.



Figura 2. TODOS del archivo muestreo.R

3.3. Completar el archivo clasificación_variables.py

En este código me encargué de analizar y estructurar las variables de la base de datos de clientes en GOOGLE COLAB. Primero exploré los tipos de datos y los valores únicos de cada columna, luego convertí las variables ordinales (como el nivel de educación y el nivel de satisfacción) en factores ordenados para respetar su jerarquía real.

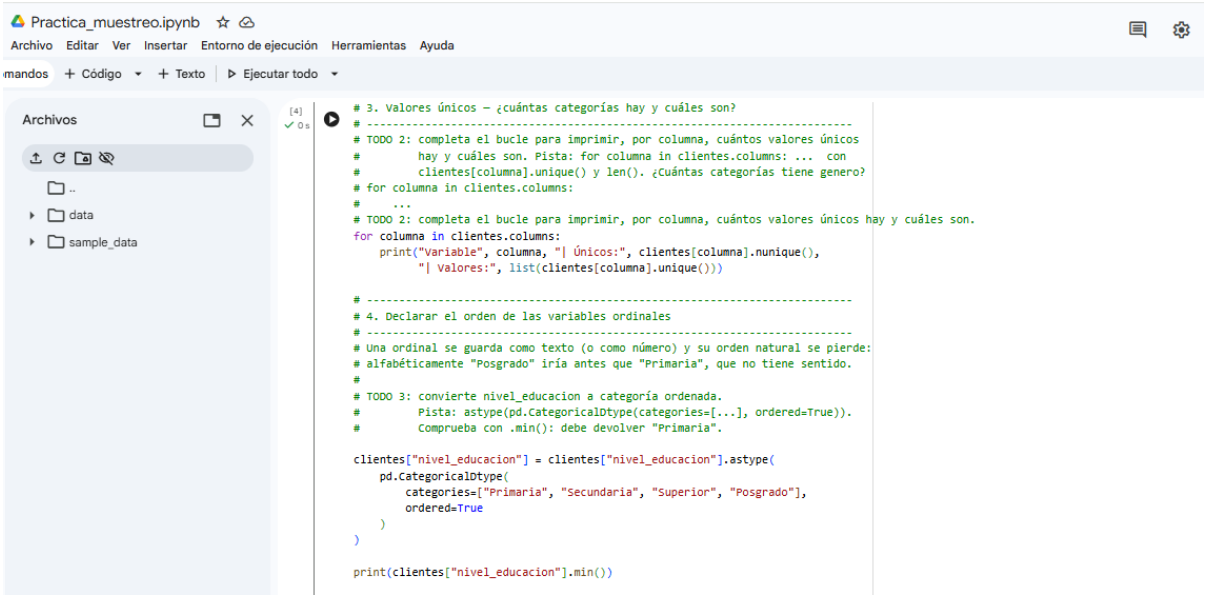


Figura 3. TODO 2 Y 3 del archivo clasificación_variables.py

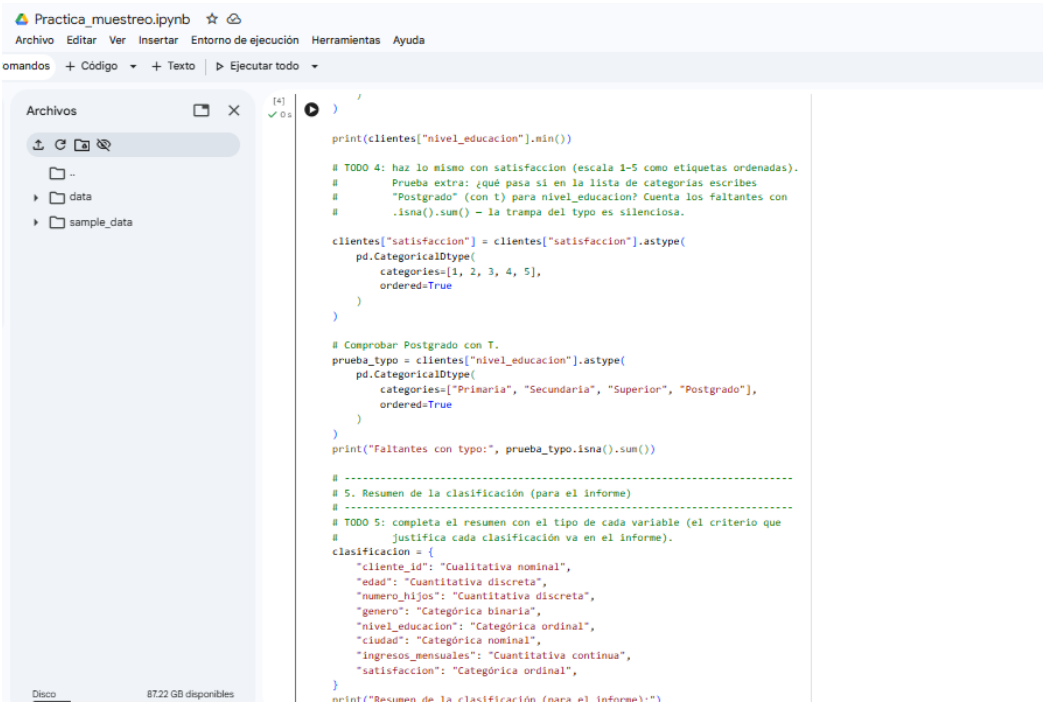


Figura 4. TODO 4 Y 5 del archivo clasificación_variables.py

3.4. Completar el archivo clasificación_variables.R

Ejecuté con éxito ambos scripts en R y Python para analizar la base de datos de clientes. Verifiqué las dimensiones, exploré los valores únicos de cada columna, declaré las variables ordinales y comprobé el resumen final para el informe. Es decir, lo mismo que en el archivo clasificación_varibales.py.

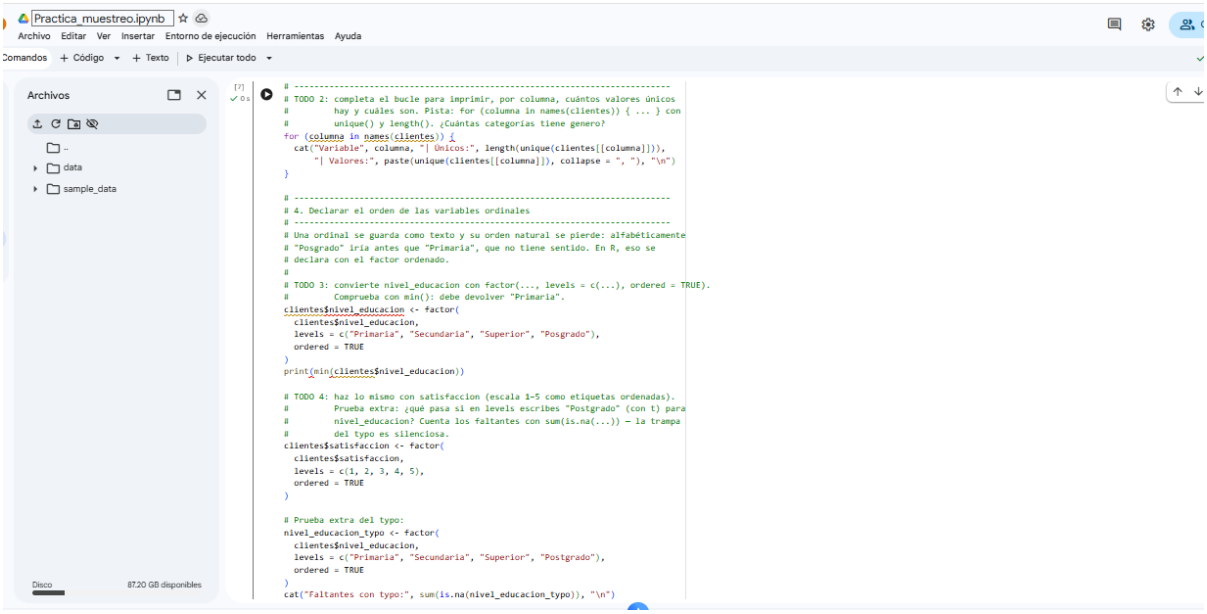


Figura 5. TODOS del archivo clasificación_variables.R

3.1 · Parte A · Clasificación de las variables

La base de trabajo es `data/clientes.csv`: **12 clientes, 7 variables + el identificador.**

Variable	Tipo	Justificación (criterio)	Verificación en código
`cliente_id`	Cualitativa nominal	Funciona puramente como una etiqueta de identificación única; no aplican operaciones aritméticas.	object (Python) / chr (R), con 12 valores únicos (C001 a C012).
`edad`	Cuantitativa discreta	Representa una cantidad numérica exacta de años cumplidos; es una magnitud contable de tiempo.	int64 (Python) / int (R), con 12 valores únicos numéricos.
`numero_hijos`	Cuantitativa discreta	Cuenta elementos enteros y discretos; no existen decimales como "1.5 hijos" en el contexto.	int64 (Python) / int (R), con 5 valores únicos de conteo (0, 1, 2, 3, 4).
`genero`	Categórica nominal	Agrupa a los registros en categorías cualitativas excluyentes sin orden inherente.	object (Python) / chr (R), con 3 valores únicos ("Femenino", "Masculino", "Otro").
`nivel_educacion`	Categórica ordinal	Posee una jerarquía de menor a mayor grado.	object / chr, orden declarado explícitamente con CategoricalDtype / factor(ordered=TRUE).

Variable	Tipo	Justificación (criterio)	Verificación en código
`ciudad`	Categórica nominal	Agrupa registros por ubicación geográfica sin importar jerarquías.	object (Python) / chr (R), con 3 valores únicos ("Quito", "Guayaquil", "Cuenca").
`ingresos_mensuales`	Cuantitativa continua	Admite infinitos valores intermedios y operaciones de magnitud.	int64 (Python) / int (R), con 12 valores únicos.
`satisfaccion`	Categórica ordinal	Mide una escala valorativa del 1 al 5, los números actúan como etiquetas ordenadas donde "4 no es el doble de 2".	int64 / int, escala del 1 al 5 convertida a categoría ordenada para preservar su jerarquía lógica.

P1. ¿Qué te dijo el dtype de `satisfaccion` y por qué no basta para clasificarla? ¿Qué pasa si una ordinal queda como texto sin declarar el orden?

El dtype me indicó que satisfacción era un número entero, pero esto no basta para clasificarla porque el sistema solo ve el almacenamiento técnico; además, si dejo una variable ordinal como texto sin declarar su orden, el programa la organizaría alfabéticamente, destruyendo por completo su jerarquía lógica natural.

3.2 · Parte B · Población vs. Muestra

Concepto	Valor
Población (N)	400 clientes (N = 400)
Variable de interés	`ingresos_mensuales`
Parámetro poblacional (media)	1,330.72 USD
¿Por qué se muestrea si aquí el parámetro existe y se calculó?	Aunque en este ejercicio la población completa es de 400 clientes y pude calcular el parámetro exacto, en la práctica real se muestrea porque analizar a toda una población requiere tiempo y recursos excesivos.

Diseño	n	Media estimada	Composición por ciudad	Diferencia vs.parámetro
Conveniencia (head)	20	$1,348.50	{'Quito': 20}	+17.78
Aleatorio simple (sample)	20	$1,336.00	{'Cuenca': 8, 'Quito': 8, 'Guayaquil': 4}	+5.28
Estratificado (groupby + 5 %)	20	$1,287.50	{'Quito': 10, 'Guayaquil': 6, 'Cuenca': 4}	-43.22

Anota también las medias de 5 sorteos distintos del aleatorio simple (semillas 1 a 5):

Semilla	1	2	3	4	5
Media	$1,336.00	$1405.00	$1235.00	$1491.50	$1288.00

P2. ¿Cuánto vale el parámetro poblacional y cuánto estimó cada diseño? ¿Cuál quedó más cerca y por qué eso no alcanza para declarar un ganador?

El parámetro poblacional con N =400 es 1,330.72 USD. En esta ejecución con la semilla 1, el diseño Aleatorio Simple quedó más cerca con 1,336.00 USD (diferencia de +5.28 USD), frente a el espacio de Conveniencia (1,348.50 USD) y con Estratificado (1,287.50 USD). Pero, un solo número no basta para declarar un ganador porque esa cercanía es producto del azar de una semilla específica; necesito evaluar la distribución y variabilidad a través de múltiples muestras para determinar cuál diseño es consistentemente mejor.

P3. La muestra por conveniencia también tiene 20 filas. ¿Qué defecto tiene y cómo lo delata en la composición por ciudad? ¿Se corrige tomando más filas?

El defecto es el sesgo de selección. Su composición por ciudad lo delata inmediatamente al mostrar que el 100 % de los registros pertenecen a Quito ({'Quito': 20}), omitiendo por completo a Guayaquil y Cuenca. Este problema no se corrige tomando más filas mediante un simple .head(), ya que solo seguiría capturando datos bajo el mismo orden original de la base, perpetuando la falta de representación territorial.

P4. El sorteo aleatorio dio un número distinto en cada semilla. ¿Qué implica esa variabilidad para una empresa que va a decidir con un solo estudio?

Implica un riesgo alto por error de muestreo. Si RetailAndina S.A. toma una decisión gerencial basada en una única muestra (una sola semilla), asume el riesgo de operar sobre un valor que se desvió por pura suerte del parámetro real. Esto demuestra que las decisiones estratégicas no deben basarse en un estudio aislado sin medir la variabilidad o intervalos de confianza.

P5. ¿Cuándo usarías cada diseño en la práctica? Relaciona cada uno con un uso real (piloto, subgrupos que deben aparecer, conclusión sobre toda la población).

Conveniencia: Lo usaría exclusivamente para un estudio piloto o pruebas operativas rápidas y de bajo costo donde no se busquen inferencias poblacionales.

Estratificado: Lo aplicaría cuando existan subgrupos que deben aparecer obligatoriamente en proporciones reales (como las ciudades de Quito, Guayaquil y Cuenca) para garantizar comparaciones válidas.

Aleatorio simple: Lo utilizaría para obtener una conclusión sobre toda la población cuando esta sea homogénea y cada elemento deba tener exactamente la misma probabilidad de selección.

4 · ¿Qué aprendí con esta práctica?

Al finalizar este trabajo práctico, reconozco un cambio radical en mi forma de analizar conjuntos de datos. El `dtype` de una variable como `satisfaccion` no basta para clasificarla: aunque se almacene técnicamente como un número entero (`int`), su

verdadera naturaleza es ordinal y requiere una declaración explícita de jerarquía para evitar que operaciones matemáticas distorsionen los resultados.

Lo más difícil de todo este proceso fue comprender el impacto real del sesgo de selección y la variabilidad muestral. Al principio, cuando ejecuté la muestra por conveniencia (`head`). Asimismo, me costó asimilar que un solo sorteo con una semilla fija (`random_state=1`) podía hacer ganar a un diseño por casualidad, ocultando su verdadera estabilidad. Resolví este obstáculo contrastando de forma metódica las composiciones por ciudad y ejecutando el bucle de múltiples semillas (del 1 al 5) en los scripts, lo que me permitió comprobar con datos numéricos reales que una sola muestra jamás es suficiente para evaluar la calidad de un diseño.

5 · Conclusiones

1. Al finalizar el trabajo de laboratorio, aprendí que elegir muestras por simple conveniencia (head) destruye la representatividad de los datos, ya que un criterio no probabilístico puede excluir por completo a regiones enteras como ocurrió al dejar fuera a Guayaquil y Cuenca, demostrando que un mal diseño arruina cualquier análisis posterior.

2. Además, aprendí que confiar en una sola muestra o en una única semilla (random_state) es un error metodológico grave, ya que la variabilidad aleatoria hace que cada sorteo fluctúe; por eso, evaluar múltiples escenarios es indispensable para saber qué tan estable es el resultado.

3. Finalmente a la gerencia le recomendaría que, antes de aceptar o solicitar un estudio basado en muestras, exija total transparencia sobre cómo se recolectó la información y si se verificó la estabilidad de las estimaciones, evitando así tomar decisiones estratégicas de alto impacto basadas en datos frágiles o sesgados.

6 · Bibliografía

1. pandas development team. (2024). *pandas documentation.* https://pandas.pydata.org/docs/
2. R Core Team. (2024). *R: A Language and Environment for Statistical Computing.* R Foundation for Statistical Computing, Vienna, Austria. https://www.R-project.org/

Declaro haber usado el 5% de IA para realizar el laboratorio. Especialmente para corregir diminutos errores de código.